# Interactive Speaker Recognition

## Применение обучения с подкреплением для решения задачи распознавания диктора

Вячеслав Головин
Александр Самарин (руководитель)

Huawei CBG AI и ФКН ВШЭ СПб

11.04.2023

# Мотивация

**Задача:** повышение точности систем верификации / идентификации диктора без использования длинных или строго фиксированных аудиозаписей.

**Предлагаемое решение:** использование агента, выбирающего в зависимости от контекста, какое слово должен произнести диктор. Для обучения агента предлагается использовать reinforcement learning (RL).

# Interactive Speaker Recognition

Метод был предложен в статье *A Machine of Few Words — Interactive Speaker Recognition with Reinforcement Learning*, Mathieu Seurin et al., INTERSPEECH 2020, arXiv:2008.03127v1.

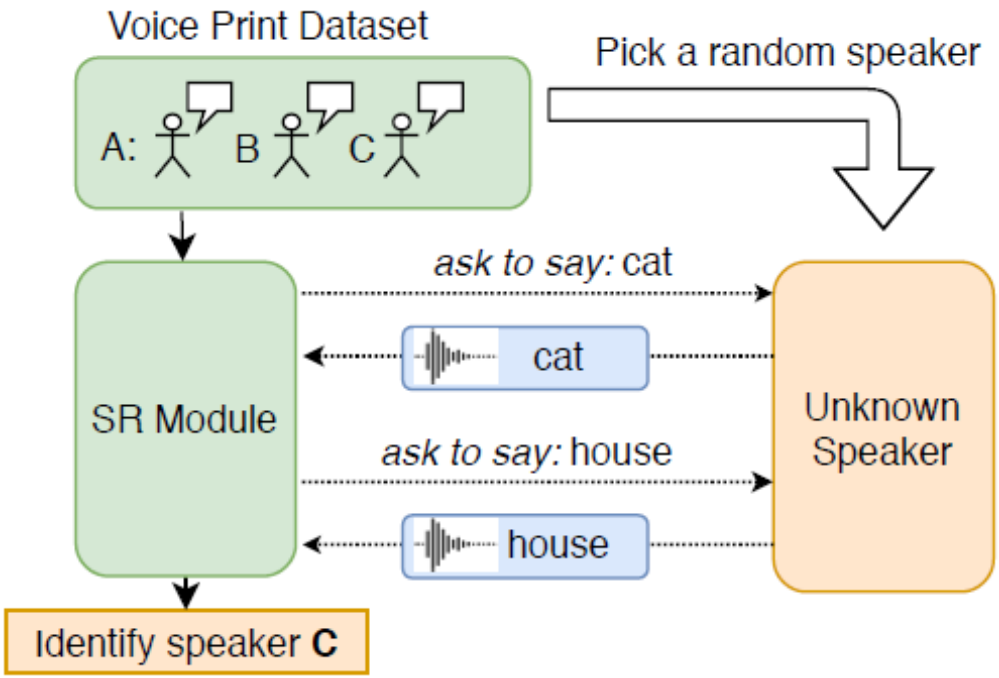


**SR Module** состоит из 2 частей:

- **Guesser** выполняет идентификацию, обучается с помощью supervised learning.
- **Enquirer** запрашивает слова, обучается с помощью reinforcement learning.

# Блок Guesser

## Архитектура

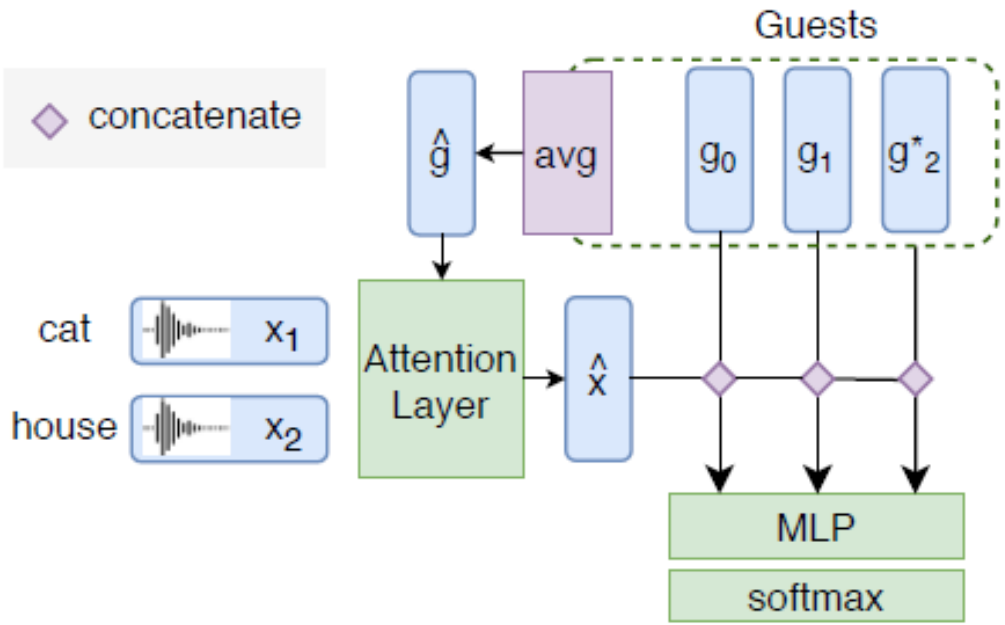


Входные данные:

- эмбеддинги дикторов $G = [g_1; g_2; \dots g_K]$
- эмбеддинги слов $X = [x_1; x_2; \dots x_T]$

Выходные данные:

- вероятности $\{P(g_i = g^*) \mid i = 1..K\}$

## Обозначения

| | |
|---|---|
| $K$ | количество гостей / дикторов |
| $T$ | количество запрашиваемых слов |

# Блок Guesser

## Псевдокод 1 итерации обучения

```
speaker_ids = speakers.sample(size=K)
G = voice_prints.get(speaker_ids)
target = randrange(0, K)
word_inds = randrange(0, V, size=T)
X = word_vocab.get(speaker=speaker_ids[target],
                   words=word_inds)
prediction = guesser.forward(G, X)
loss = cross_entropy(prediction, target)
```

### Обозначения

| | |
|---|---|
| $K$ | количество гостей / дикторов |
| $T$ | количество запрашиваемых слов |
| $V$ | размер словаря — число доступных для запроса слов |

# Блок Enquirer

## Архитектура

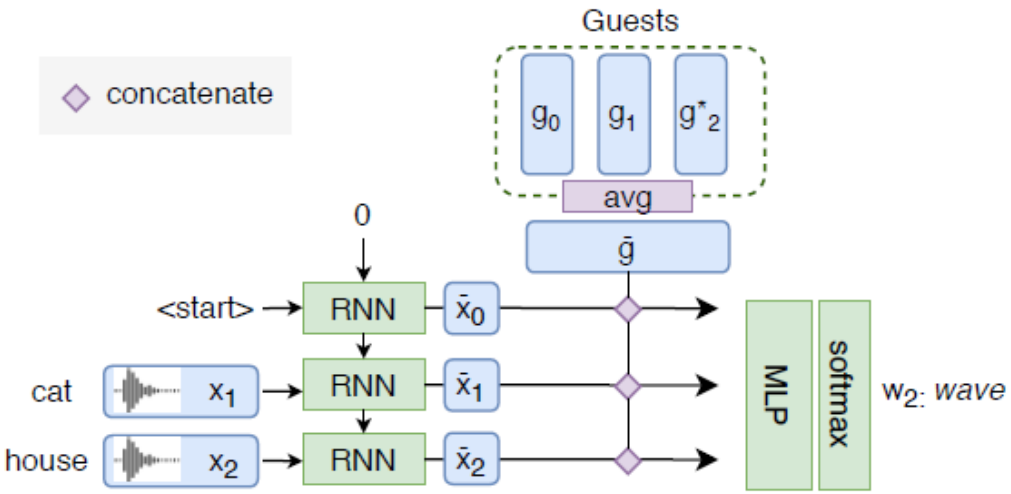


Входные данные:

- среднее эмб. дикторов $\hat{g} = \frac{1}{K}\sum_{i=1}^{K} g_k$
- эмбеддинги слов $X = [x_1; x_2; \ldots; x_t]$

Выходные данные:

- вероятность выбрать каждое из слов

## Обозначения

| | |
|---|---|
| $K$ | количество гостей / дикторов |
| $T$ | количество запрашиваемых слов |
| $t$ | количество запрошенных слов, $0 \leq t \leq T$ |

# Блок Enquirer

## Псевдокод 1 эпизода ISR-игры

```
speaker_ids = speakers.sample(size=K)
G = voice_prints.get(speaker_ids)
target = randrange(0, K)

g_hat = G.mean(dim=0)
x_i = start_tensor
X = []
for i in range(T):
    probs = enquirer.forward(g_hat, x_i)
    if training:
        distribution = multinomial(probs)
        word_ind = distribution.sample()
    else:
        word_ind = argmax(probs)
    x_i = word_vocab.get(speaker=speaker_ids[target], word=word_ind)
    X.append(x_i)

prediction = guesser.predict(G, X)
reward = 1 if prediction == target else 0
```

# Входные данные

Для обучения использовался датасет **TIMIT**:

- 630 дикторов из США, 8 акцентов;
- каждый диктор произносит 10 предложений: 8 уникальных и 2 общих.

В качестве эмбеддингов использовались **x-vectors**, полученные с помощью нейронной сети, обученной на аугментированных датасетах для распознавания диктора *Switchboard*, *Mixer 6* и *NIST*.

- Эмбеддинги дикторов $g$ получались с помощью усреднения эмбеддингов 8 уникальных предложений.
- Эмбеддинги слов $x$ извлекались с помощью 2 общих предложений, т.е. сначала вырезались записи одиночных слов, которые затем пропускались через нейронную сеть.

# Результаты из статьи

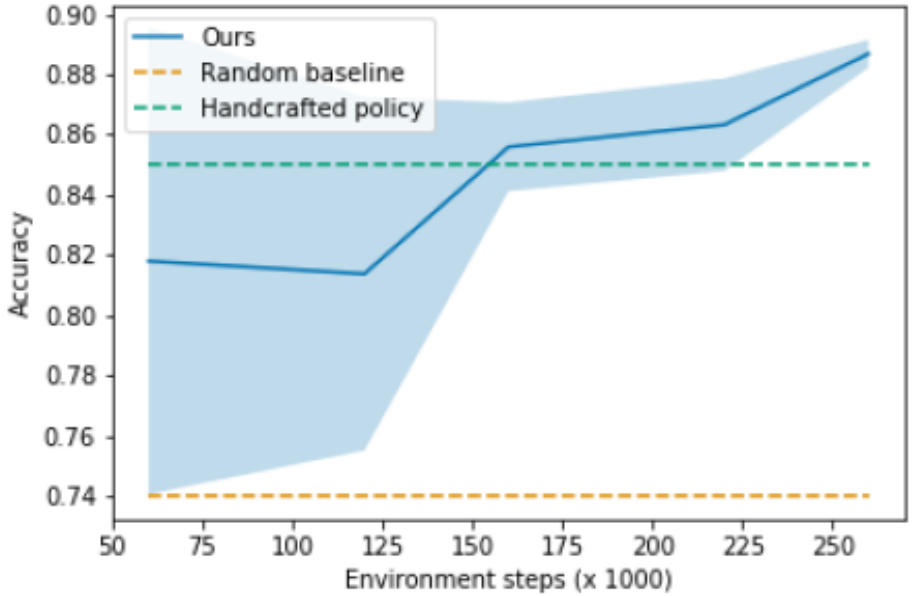


- RL-агент при выборе запрашиваемых слов учитывает контекст — он опережает не только случайного агента, но и эвристического, выбирающего из подмножества “лучших” слов.

# Результаты из статьи

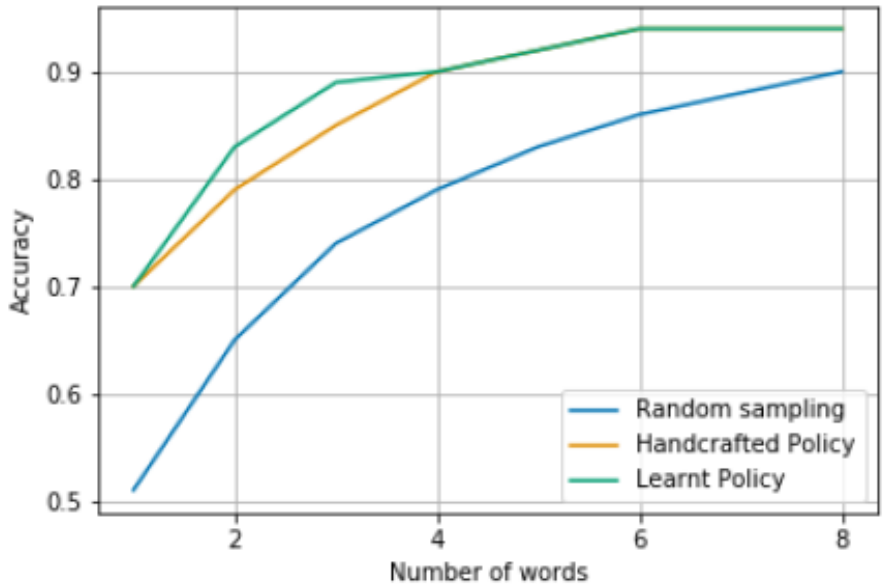


- RL-агент при выборе запрашиваемых слов учитывает контекст — он опережает не только случайного агента, но и эвристического, выбирающего из подмножества “лучших” слов.
- Преимущество RL-агента невелико и проявляется только при небольшом числе запрашиваемых слов.

# Извлечение эмбеддингов

## Цитата из статьи

We use MFCCs of dimension 20 with a frame-length of 25ms, mean-normalized over a sliding window of three seconds. We then process the MFCCs features through a pretrained X-Vector network to obtain a high quality voice embedding of fixed dimension 128 [. . . ].

- У данной нейросети есть только 512-мерные выходы.
- При обучении нейросети в `kaldi` выходы нейросети подвергаются обработке — вычитается среднее по всем дикторам и понижается размерность с помощью LDA.
- Мои попытки выполнять подобную постообработку с помощью `sklearn` / `numpy` заканчивались неудачей — при обучении `guesser` отсутствовала генерализация.
- **Итог**: я использовал 512-мерные эмбеддинги, получаемые напрямую с выходов нейросети.

# Обучение Guesser — первые результаты

$K = 5$ дикторов и $T = 3$ слова

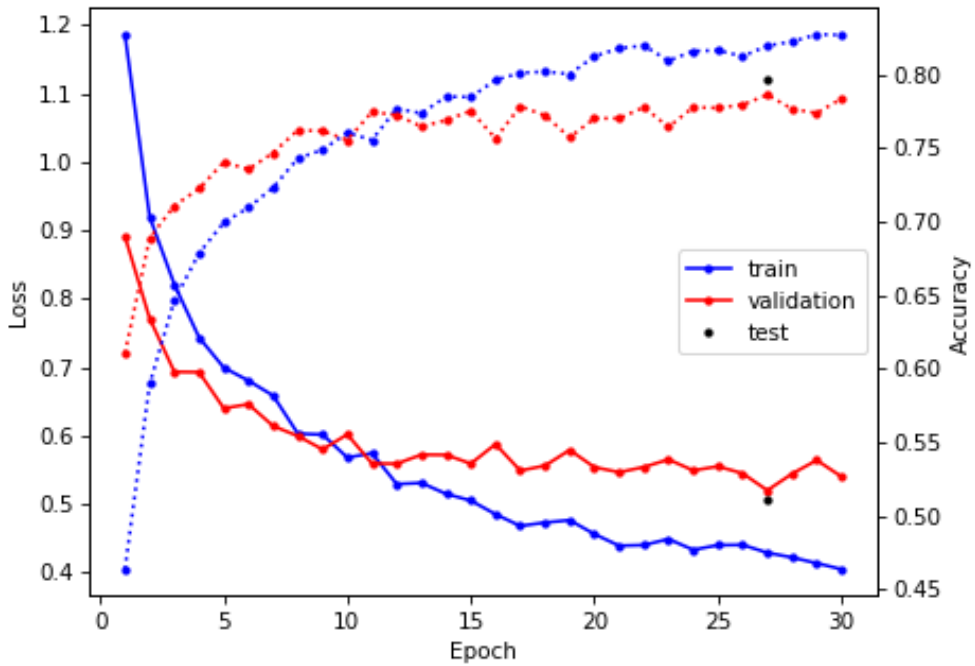


Увеличение размерности эмбеддингов $d$ со 128 до 512 позволило существенно улучшить точность (∼80% вместо 74.1% в оригинальной статье).

# Обучение Enquirer — первые результаты

$K = 5$ дикторов и $T = 3$ слова

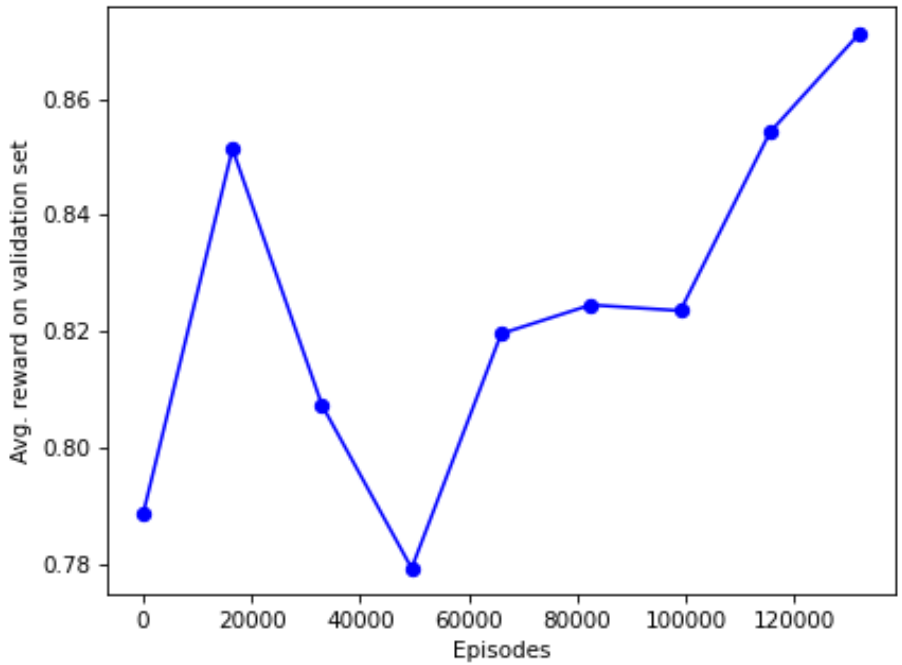


- Точность ниже, чем в статье (88.6%), но явно есть возможность её улучшить.
- Обучение с помощью PPO, награда $R = 1$ выдается в том случае, когда в конце эпизода guesser правильно угадывает диктора.

# Обучение Guesser — подбор гиперпараметров

$K = 5$ дикторов и $T = 3$ слова

Средняя награда (точность) на валидационной выборке:

| | | learning rate | | | |
|---|---|---|---|---|---|
| | | 1.00E-03 | 5.00E-04 | 1.00E-04 | 5.00E-04 |
| batch size | 20 | 73.6 | 78.0 | 89.0 | 88.3 |
| | 40 | 78.7 | 87.0 | 91.7 | 90.3 |
| | 80 | 80.6 | 89.8 | 93.0 | 92.4 |
| | 160 | 81.7 | 91.0 | 92.7 | 92.5 |

- Такая же точность достигается и на тестовой выборке.
- Обучение enquirer позволяет увеличить точность до 96%.

# Дальнейшие планы

- Оптимизация гиперпараметров и доработка enquirer.
- Реализация эвристических агентов и сравнение их с нейросетевой моделью.
- Проведение экспериментов в более тяжёлых режимах (больше дикторов, меньше слов).
- Использование других эмбеддингов.
- Исследование робастности модели.
- Эксперименты с архитектурой enquirer / guesser.